

Planeamento de Cirurgias Electivas

Programação por restrições baseada em intervalos (CP-SAT) para planeamento semanal de blocos operatórios

Hector Bonilla

Agenda

- 1 Problema e Motivação
- 2 Pressupostos e Âmbito
- 3 Dados e Instâncias
- 4 Modelo CP-SAT
- 5 Porquê CP-SAT e Não MIP
- 6 Resultados
- 7 Deployment em Produção
- 8 Arquitectura e Reutilização

Fluxo principal: modelo CP-SAT completo – variáveis, parâmetros e restrições em detalhe. O modelo MIP de comparação está no apêndice – é evidência para a escolha CP-SAT, não um segundo modelo a apresentar.

O problema

Um hospital, uma semana. Uma lista de espera cirúrgica sempre maior do que a capacidade semanal dos blocos operatórios.

- Para cada caso em espera: qual bloco, qual dia, que hora, qual cirurgião – ou adiar para a semana seguinte.
- **Viabilidade:** blocos, cirurgiões, equipamento partilhado e camas de recuperação são todos finitos e partilhados.
- **Equidade clínica:** a urgência clínica, e não a ordem de chegada, deve determinar prioridade – um doente genuinamente urgente não pode ficar atrás de um caso rotineiro.
- **Âmbito (Cardoen et al., 2010):** este é o problema de *planeamento antecipado* – atribuição de casos a dias/blocos com antecedência – distinto da sequenciação intra-dia e da gestão de perturbações em tempo real.

Porquê é importante

- **O tempo de bloco operativo é caro e perecível.** ~ \$30–40/minuto uma vez amortizados pessoal, equipamento e overhead (Macario, 2010). Um minuto de bloco inactivo hoje não pode ser guardado para amanhã.
- **A lista de espera é o indicador auditado.** Em sistemas como o SIGIC português, o RTT do NHS britânico e os benchmarks provinciais canadianos, a taxa de incumprimento dos prazos é o número que é publicado e pelo qual o planeador é avaliado.
- **Procura electiva e urgente partilham os mesmos blocos** (Van Riet & Demeulemeester, 2015) – a alocação de capacidade é uma decisão estratégica, não um subproduto do agendamento.
- **Evidência na literatura:** Cardoen, Demeulemeester & Beliën (2010) revêem mais de 200 artigos; o planeamento antecipado com restrições de prioridade/prazo é um sub-problema bem definido, que este projecto ocupa na sua totalidade.

O caso português: o sistema SIGIC

SIGIC – *Sistema Integrado de Gestão de Inscritos para Cirurgia* – é o sistema nacional português de gestão da lista de espera cirúrgica, estabelecido pela **Portaria n.º 45/2008** (Diário da República).

Cada caso electivo é classificado numa de **quatro prioridades clínicas**, com um **tempo máximo de espera** associado:

Prioridade	Significado clínico	Espera máxima (dias)
1	Electivo de rotina	270
2	Urgência elevada	60
3	Urgente	15
4	Emergente/adicional – deve operar esta semana	3

Estes quatro números *não* são valores ilustrativos inventados para a demo – são os parâmetros wl_p^{max} do modelo, retirados directamente de uma política legislada e auditada.

O caso português: a auditoria CHLN de 2016

Marques & Captivo (2015) auditaram a lista de espera do Centro Hospitalar Lisboa Norte (CHLN) face às metas SIGIC. Principais conclusões:

- ~**7 400** doentes na lista no momento da auditoria.
- **16%** já tinha *ultrapassado* o prazo máximo da respectiva prioridade.
- Atraso médio entre os casos em incumprimento: **147 dias** a nível hospitalar.
- Neurocirurgia: atraso médio de ~**261 dias** – muito acima da média hospitalar.

O caso português: a auditoria CHLN de 2016

Marques & Captivo (2015) auditaram a lista de espera do Centro Hospitalar Lisboa Norte (CHLN) face às metas SIGIC. Principais conclusões:

- ~**7 400** doentes na lista no momento da auditoria.
- **16%** já tinha *ultrapassado* o prazo máximo da respectiva prioridade.
- Atraso médio entre os casos em incumprimento: **147 dias** a nível hospitalar.
- Neurocirurgia: atraso médio de ~**261 dias** – muito acima da média hospitalar.

Porque é que isto molda o objectivo deste modelo

Um planeador que optimize apenas o volume pode apresentar uma excelente utilização e reproduzir silenciosamente o modo de falha desta auditoria – agendando casos de rotina e adiando os casos em incumprimento indefinidamente. O termo de penalização w_c no objectivo existe precisamente para tornar estes custos *explícitos, ponderados e dominantes*.

O que o modelo cobre – e o que não cobre

Modelado:

- Atribuição caso→bloco→hora→cirurgia
- Escalas de serviço dos blocos (block schedule)
- Disponibilidade e limites horários dos cirurgões
- Uma unidade de imagiologia partilhada (intensificador C)
- Camas de recuperação/UCI (internamento multi-dia)
- Bloqueio de prioridade 4 (dia 1)
- Regra de bloco pediátrico

Excluído deliberadamente:

- Duções estocásticas
- Perturbações intra-dia
- Escalonamento de enfermeiros/anestesiastas
- Limpeza dependente da sequência
- Horizonte multi-semana
- Dimensionamento de reserva para urgências
- Preferências dos doentes por dia

Pressupostos chave – detalhe e justificação

- 1 Durações determinísticas.** Uma duração por caso (ex.: mediana histórica do procedimento). As durações reais são estocásticas e tendem a ser subestimadas; o caso determinístico é a aproximação tratável padrão (Denton et al., 2010). A extensão estocástica requer programação estocástica de dois estágios.
- 2 Limpeza por escalão de duração (15/25/40 min):** proxy para o intervalo real de 15–60 min; captura a componente correlacionada com a duração, não a dependente da sequência.
- 3 Cirurgiões como recurso de pessoal limitante.** Enfermeiros/anestesiistas assumidos com o bloco – válido quando a agenda do cirurgião é o verdadeiro bottleneck.
- 4 Uma ocorrência por doente por semana.** Padrão conservador; combinar procedimentos no mesmo dia é julgamento clínico específico do serviço.
- 5 Capacidade de camas constante na semana,** com penalização de transbordo explícita – sem aproximação silenciosa.
- 6 Bloco pediátrico** como exemplo de regra institucional ad hoc: apenas um predicado de elegibilidade, sem novas variáveis.
- 7 Uma semana, um hospital, sem perturbações intra-dia** – planeamento antecipado apenas.

Modelo de dados

A camada de dados (`src/model/types.py`) é independente do solver – dataclasses Python simples, sem importações do solver.

- **SurgicalCase**: id do doente, serviço, cirurgião, prioridade p_c , dias em espera wl_c , tempo operatório t_c^{op} , limpeza t_c^{clean} , equipamento opcional, cama opcional.
- **Surgeon**: limite diário k_{hd} , limite semanal k_h , disponibilidade por dia.
- **OperatingRoom**: capacidade por dia k_{dr} , escala de serviço, flag de ambulatório.
- **PlanningInstance**: agrega tudo acima mais os parâmetros de política (wl_p^{max} , μ_p , α , capacidades de equipamento/cama, regra pediátrica).

Cada solver lê **PlanningInstance** e devolve **SolverResult** – o padrão adaptador que torna os backends intercambiáveis.

demo_instance() – 20 casos, 5 blocos, 6 cirurgiões

3 serviços: ORL (otorrinolaringologia), ORTHO (ortopedia), VASC (cirurgia vascular).

Serviço	Blocos	Capacidade (min/dia)	Cirurgiões
ORL	2	360 ($\approx$ 6 h)	2
ORTHO	1	450 ($\approx$ 7.5 h)	1
VASC	2	660 ($\approx$ 11 h)	3

Características especiais activadas (uma por família de restrições):

- 3 casos prioridade-4 (C05 ORL, C13 ORTHO, C19 VASC) – bloqueados à 2ª feira
- Intensificador C partilhado, capacidade 1/dia (VASC endovascular: C14, C15, C17, C19)
- 2 camas de UCI/dia; C14 e C16 necessitam de 1 dia de internamento
- Bloco pediátrico: 6ª feira no serviço ORL restrito a idade ≤ 8
- 3 casos em incumprimento (C03, C11, C16) – já ultrapassaram o prazo SIGIC

Dimensionada para ser lida de vista e para exercitar *todas* as famílias de restrições numa execução.

medium_instance() – 200 casos, 12 blocos, 17 cirurgias

5 serviços; estrutura inspirada na família de benchmarks multi-serviço de Cardoen et al. (2010).

Serviço	Blocos	Cap. (min/d)	Cirurgias	Equipamento
ORL	2	360	3	–
ORTHO	3	480	4	–
VASC	2	660	3	Intensificador C
GIN	2	300	3	–
NEURO	3	540	4	Intensificador C

- Mix de prioridades: 58% P1 / 26% P2 / 13% P3 / 3% P4
- ~40% dos cirurgias têm uma folga/semana (nunca 2ª feira)
- 12% dos casos VASC/NEURO necessitam de cama UCI (1–2 dias)
- Limites dos cirurgias: 300 min/dia, 1300 min/semana

Usada para demonstrar escalabilidade e medir o desfasamento CP-vs-MIP (secção de resultados).

Disponibilidade de dados reais

As instâncias sintéticas acima são estruturalmente calibradas. Existem dois conjuntos de dados hospitalares reais com licença aberta que se mapeiam directamente para `PlanningInstance` sem qualquer alteração à formulação:

- Akbarzadeh & Maenhout (2023a). *Real life data for OR scheduling* – registo de blocos do Hospital Universitário de Ghent, Maio 2017. Mendeley Data V2. doi:10.17632/n2v49z2vnp.2
- Akbarzadeh & Maenhout (2023b). *RealLife OR scheduling dataset, 2021-Jan-May* – 20 instâncias semanais, 8 configurações. Mendeley Data V1. doi:10.17632/c8d342266x.1

Ambos são CC BY 4.0 e contêm o mesmo esquema de escala mestre + lista de espera por caso usado por `PlanningInstance`. Um deployment real começaria aqui.

Conjuntos e índices

Símbolo	Significado
$c \in C$	Casos cirúrgicos (um por par doente-procedimento)
$d \in D$	Dias de planeamento, $D = \{1, \dots, 5\}$ (2ª–6ªfeira)
$r \in R$	Blocos operatórios
$h \in H$	Cirurgiões
$e \in E$	Tipos de equipamento partilhado
$D_c \subseteq D$	Dias elegíveis para o caso c ; $\{1\}$ se prioridade-4

Os candidatos (c, d, r) são pré-filtrados por elegibilidade (C4–C6) *antes* de qualquer variável ser criada – esta é a principal redução do número de variáveis, não uma restrição adicional.

Parâmetros (I): tempo, capacidade, prioridade

Símbolo	Significado	Valor padrão / origem
t_c^{op}	Duração operatória (min)	Mediana histórica
t_c^{clean}	Limpeza (min)	15/25/40 por escalão de duração
$t_c^{tot} = t_c^{op} + t_c^{clean}$	Ocupação total do bloco	—
k_{dr}	Minutos de abertura do bloco r no dia d	Escala hospitalar
k_{hd}	Limite operatório diário do cirurgião (min)	240 (demo) / 300 (médio)
k_h	Limite operatório semanal do cirurgião (min)	960 (demo) / 1300 (médio)
$p_c \in \{1, 2, 3, 4\}$	Prioridade clínica	Triagem SIGIC
wl_c	Dias em espera (data de planeamento)	Dados hospitalares
wl_p^{max}	Espera máxima para prioridade p	270/60/15/3 (SIGIC)
$dd_c = wl_{p_c}^{max} - wl_c$	Folga ao prazo (< 0 = incumprimento)	Calculado

Parâmetros (II): objectivo e recursos partilhados

Símbolo	Significado	Valor padrão / origem
μ_p	Multiplicador de prioridade	wl_1^{max} / wl_p^{max} (derivado)
w_c	Penalização por não agendamento	$\mu_{p_c} \cdot \text{PenaltyCurve}(dd_c) + 1.2 \max dd$
$\alpha > 1$	Amplificador de urgência para casos em atraso	2.0 (controlo de ordem)
$u_{ce} \in \{0, 1\}$	1 se o caso c necessita do equipamento e	Dados da instância
κ_{ed}	Capacidade simultânea do equip. e no dia d	1 (demo), 2 (médio)
$\rho(c)$	Pool de camas necessária ("none" se não aplicável)	Dados da instância
los_c	Dias de internamento nessa pool	Dados da instância
β_ρ	Número de camas na pool ρ (constante/semana)	2 (demo), 6 (médio)
π^{ovf}	Penalização/dia por estadia além do horizonte	50 (configurável)

μ_p : prioridade autorizada a apenas 1/12 da espera de P1 é $12\times$ mais sensível ao tempo de espera:

$\mu_2 = 270/60 = 4.5$, $\mu_3 = 270/15 = 18$, $\mu_4 = 270/3 = 90$.

Variáveis de decisão – presença e agendamento

Para cada (c, d, r) que passa na elegibilidade:

$$\text{pr}_{cdr} \in \{0, 1\}, \quad \text{start}_{cdr}, \text{end}_{cdr} \in [0, k_{dr}]$$

Para cada caso que não é prioridade-4:

$$u_c \in \{0, 1\}, \quad \sum_{d \in D_c, r} \text{pr}_{cdr} + u_c = 1$$

- $\text{pr}_{cdr} = 1$: o caso c é agendado no dia d no bloco r .
- $u_c = 1$: o caso c *não* é agendado esta semana e incorre na penalização w_c .
- Os casos de prioridade-4 não têm u_c : são forçados a ser agendados (restrição C2).
- Apenas os trios (c, d, r) que passam C4–C6 têm variável – principal redução do número de variáveis.

Variáveis de decisão – dois intervalos por candidato

$iv_{cdr} = \text{NewOptionalIntervalVar}(\text{start}_{cdr}, t_c^{tot}, \text{end}_{cdr}, pr_{cdr})$ (BLOCO)

$sgiv_{cdr} = \text{NewOptionalIntervalVar}(\text{start}_{cdr}, t_c^{op}, \text{sgend}_{cdr}, pr_{cdr})$ (CIRURGIÃO)

Ambos partilham *start*; ambos estão *presentes* (restringem o recurso) exactamente quando $pr_{cdr} = 1$.

Variáveis de decisão – dois intervalos por candidato

$iv_{cdr} = \text{NewOptionalIntervalVar}(\text{start}_{cdr}, t_c^{tot}, \text{end}_{cdr}, pr_{cdr})$ (BLOCO)

$sgiv_{cdr} = \text{NewOptionalIntervalVar}(\text{start}_{cdr}, t_c^{op}, \text{sgend}_{cdr}, pr_{cdr})$ (CIRURGIÃO)

Ambos partilham start ; ambos estão *presentes* (restringem o recurso) exactamente quando $pr_{cdr} = 1$.

Porquê dois intervalos e não um?

O cirurgião H opera o Caso X: $t_c^{op} = 70$, $t_c^{clean} = 20$, início em $t = 0$. O *bloco* fica ocupado até $t = 90$. O *cirurgião* fica livre em $t = 70$ e pode entrar no Bloco 2 para o Caso Y enquanto os enfermeiros terminam a limpeza do Bloco 1. Usar um único intervalo de tamanho t_c^{tot} para C8 proibiria incorrectamente esta situação. Separar C7 (bloco, t_c^{tot}) de C8 (cirurgião, t_c^{op}) com o mesmo start resolve isto sem restrições de ligação explícitas.

Variáveis CP-SAT – referência formal completa

Variável	Domínio	Significado
pr_{cdr}	$\{0, 1\}$	1 se o caso c é agendado no dia d no bloco r ; criada apenas para trios (c, d, r) elegíveis (pré-filtro C4–C6)
$start_{cdr}$	$[0, k_{dr}]$	Hora de início (min desde abertura do bloco) quando $pr_{cdr} = 1$
end_{cdr}	$[0, k_{dr}]$	Fim de ocupação do bloco = $start_{cdr} + t_c^{tot}$
iv_{cdr}	OptionalIntervalVar	Intervalo de ocupação do Bloco : $[start, start + t_c^{tot}]$; activo iff $pr_{cdr} = 1$; usado em C7, C10, C11
$sgend_{cdr}$	$[0, k_{dr}]$	Fim de envolvimento do cirurgião = $start_{cdr} + t_c^{op}$
$sgiv_{cdr}$	OptionalIntervalVar	Intervalo do Cirurgião : $[start, start + t_c^{op}]$; activo iff $pr_{cdr} = 1$; usado apenas em C8. Mais curto que iv_{cdr} por t_c^{clean}
u_c	$\{0, 1\}$	1 se o caso c não é agendado (penalização w_c); só para $p_c \neq 4$. Imposto por $\sum_{d,r} pr_{cdr} + u_c = 1$
$dayof_c$	$\{0, \dots, n_d - 1\}$	Índice do dia em que c é agendado; derivado via OnlyEnforceIf de $pr_{cdr} = 1$. Apenas para casos com $\rho(c) \neq \text{none}$
bed_c	OptionalIntervalVar	Intervalo de UCI/recuperação: $[dayof_c, dayof_c + los_c]$; presente iff $1 - u_c = 1$; alimenta Cumulativo de C11
$overflow_c$	$[0, los_c]$	Dias de estadia além do horizonte: $\max(0, dayof_c + los_c - n_d)$; acrescenta Termo 4 ao objectivo

Função objectivo – fórmula completa

$$\begin{aligned}
 \min \quad & \underbrace{\sum_{\substack{c: dd_c \geq 0 \\ d \in D_c, r}} [dd_c + d] pr_{cdr}}_{\text{Termo 1 – casos em prazo, preferir mais cedo}} + \underbrace{\sum_{\substack{c: dd_c < 0 \\ d \in D_c, r}} [dd_c + \alpha d] pr_{cdr}}_{\text{Termo 2 – casos em atraso, urgência amplificada}} \\
 & + \underbrace{\sum_{c: p_c \neq 4} w_c u_c}_{\text{Termo 3 – penalização por não agendamento}} + \underbrace{\pi^{ovf} \sum_{c: \rho(c) \neq \text{none}} \text{overflow}_c}_{\text{Termo 4 – penalização de transbordo de camas}}
 \end{aligned}$$

- Termo 1: recompensa o agendamento de qualquer caso, preferindo dias mais cedo.
- Termo 2: $\alpha > 1$ faz o planeador adiantar os casos em atraso.
- Termo 3: termo dominante – garante que o modelo agenda em vez de descartar.
- Termo 4: penaliza estadias de camas que ultrapassam a semana.

Penalização por não agendamento w_c e calibração de prioridades

$$w_c = \mu_{p_c} \cdot \text{PenaltyCurve}(dd_c) + 1.2 \cdot \max_{c' \in C} dd_{c'}$$

PenaltyCurve (src/model/penalty.py): plana enquanto o caso tem folga, escala bruscamente em incumprimento, continua a subir com o atraso acumulado.

Multiplicadores de prioridade μ_p – *derivados* do SIGIC:

$$\mu_p = \frac{wl_1^{max}}{wl_p^{max}} \Rightarrow \mu_2 = \frac{270}{60} = 4.5, \quad \mu_3 = \frac{270}{15} = 18, \quad \mu_4 = \frac{270}{3} = 90$$

Uma prioridade autorizada a apenas 1/12 da espera de P1 é, pela *mesma* política, 12× mais sensível ao tempo de espera.

Margem de deslocamento 1.2: o mínimo necessário é $1 + \alpha n_{\text{dias}} / \max dd_c \approx 1.037$; 1.2 oferece uma margem de segurança para instâncias com $\max dd$ menor.

Restrições C1–C3: disposição dos casos

C1 – no máximo uma ocorrência por doente por semana:

$$\sum_{c: \text{doente}(c)=n} \sum_{d \in D_{c,r}} pr_{cdr} \leq 1 \quad \forall n$$

C2 – prioridade-4 bloqueada ao dia 1:

$$\sum_r pr_{c,1,r} = 1 \quad \forall c : p_c = 4 \quad (\text{todos os outros slots de } c \text{ forçados a } 0)$$

C3 – cada outro caso é agendado exactamente uma vez ou penalizado:

$$\sum_{d \in D_{c,r}} pr_{cdr} + u_c = 1 \quad \forall c : p_c \neq 4$$

C4–C6 (elegibilidade): escala de serviço do bloco, flag de ambulatório, regra de bloco pediátrico – todas resolvidas na geração de candidatos; nunca aparecem como linha de restrição.

Restrições C7–C9: bloco e cirurgião

C7 – bloco, não-sobreposição exacta:

$$\text{AddNoOverlap}(\{iv_{cdr} : d, r \text{ fixos}\}) \quad \forall d \in D, r \in R$$

C8 – cirurgião, não-sobreposição exacta no *seu* intervalo + limite diário:

$$\text{AddNoOverlap}(\{sgiv_{cdr} : \text{cirurgião}(c) = h, d \text{ fixo}\}) \quad \forall h, d$$

$$\sum_{c: \text{cirurgião}(c)=h} \sum_r t_c^{op} pr_{cdr} \leq k_{hd} \quad \forall h \in H, d \in D$$

C9 – limite semanal do cirurgião:

$$\sum_{c: \text{cirurgião}(c)=h} \sum_{d,r} t_c^{op} pr_{cdr} \leq k_h \quad \forall h \in H$$

NoOverlap limita a concorrência; C8/C9 limitam as horas totais – ambas são necessárias pois restringem coisas diferentes.

Restrições C10–C11: equipamento e camas

C10 – equipamento partilhado, verificação exacta de sobreposição:

$$\text{AddCumulative}(\{iv_{cdr} : u_{ce} = 1, d \text{ fixo}\}, \mathbf{1}, \kappa_{ed}) \quad \forall e \in E, d \in D$$

C11 – camas de recuperação/UCI, com penalização de transbordo:

$$\text{dayof}_c = d_{\text{idx}} \text{ (via OnlyEnforceIf quando } pr_{cdr} = 1)$$

$$\text{bed}_c = \text{NewOptionalIntervalVar}(\text{dayof}_c, \text{los}_c, \text{dayof}_c + \text{los}_c, 1 - u_c)$$

$$\text{AddCumulative}(\{\text{bed}_c : \rho(c) = \rho\}, \mathbf{1}, \beta_\rho) \quad \forall \rho$$

$$\text{overflow}_c = \max(0, \text{dayof}_c + \text{los}_c - n_{\text{dias}})$$

C11 necessita do valor do “dia de cirurgia” – a razão concreta pela qual este modelo é baseado em intervalos. Um MIP por dia-balde não tem esta variável (ver apêndice).

Estratégia de pesquisa CP-SAT

- **Portfólio paralelo** – vários trabalhadores de pesquisa completa com heurísticas diferentes, mais trabalhadores de Large Neighbourhood Search que melhoram um incumbente, partilhando cláusulas aprendidas via um núcleo SAT comum (Perron & Furnon, OR-Tools docs).
- **Sem estratégia de ramificação personalizada** – a orientação do OR-Tools é que o portfólio padrão supera estratégias únicas ajustadas manualmente, salvo se existir percepção estrutural não exposta já através de NoOverlap/Cumulative. Este modelo expõe essa estrutura na totalidade.
- **Trabalhadores** limitados a `os.cpu_count()` – exceder os núcleos físicos acrescenta contenção, não diversidade de pesquisa.
- **Alvo de desfasamento** = 1% por padrão; o solver para quando a melhor fronteira está dentro de 1% do incumbente actual.
- **“Óptimo”** significa dentro do desfasamento configurado, não necessariamente 0% – sempre impresso e nunca assumido zero.

O argumento central

Distinção fundamental

“Total de minutos de utilização do equipamento hoje $\leq$ capacidade” certifica que um conjunto de durações *cabe*. *Não* certifica que podem ser colocadas sem *colisão*. Para um único bloco as duas afirmações coincidem. **Deixam de coincidir** quando um recurso é partilhado por vários blocos.

MIP (por dia-balde): contagem de casos do intensificador C por dia ≤ 1 . Colocações legais proibidas: 2 casos não-sobrepostos no mesmo dia falham esta verificação.

CP-SAT: AddCumulative verifica sobreposição temporal real. Dois casos sequenciais no mesmo dia – nunca simultâneos – passam a verificação. Região viável maior, melhores agendamentos possíveis.

Vantagens e desvantagens

CP-SAT / vantagens:

- NoOverlap/Cumulative com propagação em tempo polinomial
- Horas exactas intra-dia modeladas nativamente
- Restrição C11 expressável
- Pesquisa em portfólio paralelo (LNS + pesquisa completa)
- Sem constantes big-M

CP-SAT / desvantagens:

- Desfasamento próprio pode ser mais largo
- Menos intuitivo como “LP clássico”

MILP / vantagens:

- Relaxação LP forte via teoria de planos de corte
- Solvers comerciais maduros (Gurobi, CPLEX)
- Desfasamento próprio fecha rapidamente em instâncias pequenas

MILP / desvantagens:

- Crescimento quadrático de variáveis para disjunções
- big-M enfraquece relaxação LP
- Não pode expressar C11
- Contagem de equipamento por dia é

Quando seria o MILP a escolha mais adequada?

Mesmo nesta classe de problemas, uma formulação MILP é mais natural ou prática em situações específicas:

- **Apenas atribuição de dias, sem horas exactas.** Quando o resultado necessário é “caso c opera no dia d no bloco r ” sem hora de início, o MILP por dia-balde captura isso naturalmente; variáveis de intervalo seriam engenharia a mais.
- **Sem recursos partilhados entre blocos.** Se cada equipamento está dedicado a um bloco e os cirurgiões não mudam de bloco, a restrição de contagem diária é suficiente.
- **Sem restrição multi-dia (C11 não necessária).** Quando as camas de recuperação/UCI não são modeladas, uma das razões estruturais para intervalos desaparece.
- **Instância pequena, relaxação LP apertada.** Um solver comercial (Gurobi, CPLEX) fecha o desfasamento em segundos com um certificado de optimalidade provada.
- **Necessidade de variáveis duais LP.** Os preços-sombra da relaxação LP suportam análise de sensibilidade – o CP-SAT não os expõe directamente.
- **Equipa com expertise em MILP.** Quando a equipa domina MILP mais do que CP, o risco de erros de modelação é menor com a ferramenta que conhecem melhor.

Instância demo – tabela de resultados


```
python main.py --instance demo --benchmark --gap 0.0001
```

Solver	Estado	Objectivo	Desfasamento	Agendados
CP-SAT (principal)	Óptimo	155.0	0.00%	20/20
OR-Tools/CBC (MIP)	Óptimo	157.0	0.00%	20/20
Gurobi (MIP)	Óptimo	157.0	0.00%	20/20
CP Optimizer	Óptimo	155.0	0.00%	20/20

Casos do intensificador C (4 no total: C14, C15, C17, C19):


- **CP-SAT:** $2^a=[C19]$, $3^a=[C15, C17]$, $4^a=[C14]$ – dois casos do intensificador no *mesmo dia*, sequencialmente.
- **MIP:** $2^a=[C19]$, $3^a=[C15]$, $4^a=[C17]$, $5^a=[C14]$ – um por dia, forçado pela contagem diária.

Demo – Gantt CP-SAT



Leitura: cada linha é um bloco; cada barra é um caso, colorida por serviço. Barras com contorno a negro são casos prioridade-4, bloqueados à 2ª feira. Notar na **3ª feira**: R_VASC1 e R_VASC2 têm cada um um caso do intensificador – o planificador identificou correctamente que nunca se sobrepõem em tempo, mesmo que ambos caíam no mesmo dia.

Demo – Gantt MIP de comparação



Leitura: os mesmos casos, os mesmos serviços. O MIP não tem horas exactas (formulação por dia-balde) – os casos são dispostos consecutivamente apenas para visualização. Comparar a distribuição do intensificador: cada dia (2ª a 5ª feira) tem exactamente um caso. A restrição de contagem diária está satisfeita, mas produz um agendamento desnecessariamente distribuído – região viável menor, não uma pesquisa pior.

Instância média – resultados (200 casos, 2 minutos)

Passo 1 – óptimo real do MIP via Gurobi (desfasamento próximo de zero): **74 074.0**, 130/200 agendados, em < 1 segundo.

Passo 2 – orçamento realista de 2 minutos / 1% de desfasamento:

Solver	Estado	Objectivo	Desf. próprio	vs. óptimo real	Agend.
Gurobi (referência)	Óptimo	74 074.0	0.00%	—	130/200
OR-Tools/CBC	Viável	74 116.0	0.56%	+0.06%	130/200
CP-SAT	Viável	69 956.0	6.62%	−5.56%	131/200

O CBC atinge o óptimo provado do MIP em 2 minutos. O CP-SAT **supera esse óptimo em 5.56%** agendando mais um caso – está a pesquisar uma região viável estritamente maior e correcta, não uma pesquisa pior. O desfasamento próprio (6.62%) é relativo à sua própria fronteira – um espaço maior é mais difícil de fechar.

Instância média – Gantt CP-SAT (200 casos)




O que mudaria num deployment real

- 1 **Carregador de dados:** mapear a exportação EHR/PAS do hospital para PlanningInstance. O esquema alinha com os conjuntos de dados CC BY 4.0 de Akbarzadeh & Maenhout (2023).
- 2 **Calibração de parâmetros:**
 - wl_p^{max} : metas de espera publicadas pelo próprio hospital
 - k_{hd}/k_h : comprimentos de sessão do plano de trabalho dos cirurgiões
 - μ_p : elicitação estruturada com chefes de serviço (ancorada em cenários, não em multiplicadores)
 - β_p, κ_{ed} : censo real de camas e inventário de equipamento
- 3 **Cadência semanal:** executar com orçamento de 30 min a 2 horas; resultados de 2 minutos já demonstram superação de 5.56% do óptimo MIP.
- 4 **Testes de aceitação:** estender `tests/test_model.py` com retrospecção de dados reais; qualquer reimplementação deve passar as mesmas verificações de restrições fortes.
- 5 **Monitorização de equidade:** acompanhar a quota de incumprimento por serviço em paralelo com o objectivo agregado.

Como o projecto está construído

- **CP-SAT** (`cp_sat_interval_solver.py`) – o modelo, backend por defeito, o único necessário para executar.
- **MIP de comparação** (`milp_baseline_solver.py`) – CBC / SCIP / Gurobi / CPLEX; mantido apenas como evidência empírica para a escolha CP.
- **CP Optimizer** (`cp_optimizer_solver.py`) – opcional, licença necessária; adiciona limpeza dependente da sequência; retrocede automaticamente para CP-SAT.
- `src/model/types.py` – dicionário de dados independente do solver; cada símbolo matemático mapeia para um campo.
- `src/model/penalty.py` – uma implementação de w_c , partilhada por todos os backends.
- `tests/test_model.py` – contrato de aceitação: restrições fortes verificadas na saída de cada solver em cada execução.

Diagrama do pipeline de integração CP-SAT



Cada caixa corresponde a um ficheiro no repositório. O pré-filtro (C4-C6) é executado uma vez na construção – nunca repetido. O portfólio paralelo no passo de pesquisa usa `≤cpu_count()` trabalhadores; partilham cláusulas aprendidas entre si.

Uma biblioteca reutilizável de modelos (Resposta Q&A 2)

- 1 **Tipos de dados base** – dataclasses tipadas, sem importações de solver; todos os modelos na biblioteca assentam nelas.
- 2 **Padrões de restrições** – somas de capacidade, não-sobreposição via NoOverlap, objectivo de tardança por prioridade, pré-filtro de elegibilidade. O escalonamento de enfermeiros e a alocação de camas precisam das mesmas *formas*, não do mesmo modelo.
- 3 **Templates de problemas** – compõem esses padrões numa formulação específica. Este projecto é um template.
- 4 **Camada de adaptação de solver** – um ficheiro por família de backend (MILP, CP, pesquisa local); um novo problema escolhe um backend sem reescrever a lógica de restrições.

A comparação empírica CP-vs-MIP que este projecto executa é ela própria o template para a camada 4: *argumentar* a escolha de backend a partir da estrutura do problema, *verificar* numa instância pequena, depois comprometer.

Passar o testemunho (Resposta Q&A 1)

- 1 FORMULATION.md + FORMULATION_CP.md:** enquadramento, evidência, pressupostos, todos os conjuntos/parâmetros/variáveis/ restrições com matemática completa. Uma fonte de verdade.
- 2 src/model/types.py:** as dataclasses são o dicionário de dados – cada símbolo matemático mapeia exactamente para um campo.
- 3 Código do solver com números C:** cada restrição em `cp_sat_interval_solver.py` tem a etiqueta C1...C11, coincidindo com FORMULATION_CP.md – lidos em paralelo, sem ambiguidade.
- 4 tests/test_model.py:** barra de aceitação – qualquer reimplementação deve passar as mesmas verificações de restrições fortes na instância demo; escrever um novo teste com cada nova restrição.
- 5 Um glossário curto:** a maior parte da confusão neste tipo de projecto é vocabulário (“escala de bloco”, “ambulatório”, o que significa P4 operacionalmente), não matemática.

Para onde levaria isto a seguir

Extensão	Abordagem
Durações estocásticas	PL estocástica de 2 estágios
Reagendamento intra-dia	LNS com semente no plano actual
Reserva de capacidade para urgências	Bloco de capacidade por dia fora do modelo electivo
Escalonamento de enf./anest.	Estender H , reutilizar padrão NoOverlap/cap dos cirurgiões
Horizonte multi-semana	Transportar não agendados com prioridade aumentada
Capacidade de camas variável por dia	Cumulative segmentado por dia
Equidade por especialidade	Objectivo secundário limitando quota de incumprimento
Piloto com dados reais	Conjuntos de dados CC BY 4.0 Akbarzadeh & Maenhout

Conclusões: o que as experiências demonstram

- 1 O CP-SAT encontra agendamentos estritamente melhores em ambas as instâncias.** Demo: 155.0 vs. 157.0 (MIP). Instância média: 69 956 vs. 74 074 (óptimo *provado* do MIP) – melhoria de 5.56% agendando mais um caso. A razão é sempre a mesma: região viável maior e correcta.
- 2 O desfasamento próprio não mede o que parece.** O desfasamento de 6.62% do CP-SAT e o de 0.56% do CBC são medidos face a fronteiras de *regiões viáveis diferentes*. A comparação correcta é o valor absoluto do objectivo; o CP-SAT ganha claramente.
- 3 A modelação do equipamento partilhado é o factor estrutural decisivo.** AddCumulative verifica sobreposição temporal real; a contagem diária do MIP proíbe dois casos sequenciais do intensificador C no mesmo dia mesmo quando nunca se sobrepõem.
- 4 C11 (camas de recuperação/UCI) não pode ser expressa num MIP de dia-balde.** Só este facto é justificação estrutural para CP baseado em intervalos, independentemente do desempenho.
- 5 O design de dois intervalos permite práticas reais de bloco operatório.** O cirurgião livre em $t = 70$ pode entrar num segundo bloco enquanto o Bloco 1 ainda está a ser limpo até $t = 90$.
- 6 A instância demo resolve em ~ 0.1 s com zero desfasamento provado** – inteiramente prático mesmo para suporte a decisão em tempo real.
- 7 Com um orçamento de 2 minutos, o CP-SAT já é mais valioso que o CBC.** Mais casos agendados, objectivo menor, mesmo tempo de execução.

Questões

Obrigado.

▶ Voltar à agenda

▶ Apêndice MIP completo

MIP – visão geral da formulação

O MIP de comparação (FORMULATION.md, Apêndice A) é implementado em `milp_baseline_solver.py` e executa via `--solver milp-cbc` (incluído), `milp-gurobi`, ou `milp-cplex` (licença comercial necessária).

Igual ao CP-SAT: conjuntos, pré-filtro de elegibilidade (C4–C6), prioridades, w_c do mesmo `penalty.py`.

Diferenças principais:

- Sem horas exactas intra-dia – decisões ao nível de *dia+bloco*.
- C7 e C10 são somas de capacidade lineares, não sobreposição exacta.
- C11 (camas de recuperação) *não é expressável* – uma variável de dia-balde não tem valor de “dia de cirurgia”.
- Sem Termo 4 no objectivo.

MIP – variáveis, referência completa

Variável	Domínio	Significado
x_{cdr}	$\{0, 1\}$	1 se o caso c é agendado no dia d no bloco r . Apenas criada para trios elegíveis (mesmo pré-filtro C4–C6 do CP-SAT). Determina o dia e o bloco, mas <i>não</i> a hora exacta.
z_c	$[0, 1]$	1 se o caso c <i>não</i> é agendado esta semana (só para $p_c \neq 4$). Declarada contínua – C3 força-a a $\{0, 1\}$ no óptimo porque o objectivo penaliza não-agendamento fraccionário; declará-la binária não acrescenta nenhum apertamento à relaxação LP.

Objectivo (mesma estrutura de três termos que o CP-SAT, sem Termo 4):

$$\min \sum_{c: dd_c \geq 0} \sum_{d, r} [dd_c + d] x_{cdr} + \sum_{c: dd_c < 0} \sum_{d, r} [dd_c + \alpha d] x_{cdr} + \sum_{c: p_c \neq 4} w_c z_c$$

O mesmo `penalty.py` calcula w_c – sem implementação separada por solver. Sem Termo 4 porque C11 não é expressável.

MIP – restrições e o que está em falta

C7 (bloco, soma agregada):

$$\sum_{c \in C} t_c^{tot} x_{cdr} \leq k_{dr} \quad \forall d, r$$

Para um único bloco: equivalente à não-sobreposição exacta. Para um *recurso partilhado entre blocos*: conta incorrectamente todos os usos do equipamento como se se sobrepusessem.

C10 (equipamento, contagem diária):

$$\sum_{c: u_{ce}=1} \sum_r x_{cdr} \leq k_{ed} \quad \forall e, d$$

Conta *quantos* casos do equipamento *e* caem num dia, não se se sobrepõem – principal fonte do desfasamento de 5.56% no objectivo.

Sem C11: “ bed_c começa no dia em que c é agendado” não pode ser escrito – nenhuma variável num modelo de dia-balde guarda o “dia de cirurgia” como *valor*.

CP Optimizer (opcional, apêndice)

Mantido por uma razão: **limpeza dependente da sequência** – uma matriz de transição entre casos adjacentes num bloco via `sequence_var + no_overlap(transition_matrix)`.

	Mesmo serviço	Serviço diferente
CP-SAT (por escalão de duração)	t_c^{clean} do próprio caso	igual
CP Optimizer	15 min	35 min

Instância demo: idêntico ao CP-SAT (155.0, 20/20, Óptimo) – confirmado que os intervalos de limpeza do mesmo serviço são exactamente 15 min.

◀ Agenda

Referências

- 1 Cardoen, B., Demeulemeester, E., & Beliën, J. (2010). Operating room planning and scheduling: A literature review. *EJOR*, 201(3), 921–932. doi:10.1016/j.ejor.2009.04.011
- 2 Marques, I., & Captivo, M.E. (2015). *Planeamento de cirurgias eletivas no Centro Hospitalar Lisboa Norte*. Dissertação de mestrado, Universidade de Lisboa.
- 3 Denton, B.T., Miller, A.J., Balasubramanian, H.J., & Huschka, T.R. (2010). Optimal allocation of surgery blocks to operating rooms under uncertainty. *Oper. Res.*, 58(4), 802–816. doi:10.1287/opre.1090.0791
- 4 SIGIC – Portaria n.º 45/2008, Diário da República, Portugal.
- 5 Van Riet, C., & Demeulemeester, E. (2015). Trade-offs in operating room planning for electives and emergencies. *OR Spectrum*, 37(1), 59–87. doi:10.1007/s00291-013-0345-2
- 6 Macario, A. (2010). What does one minute of operating room time cost? *J. Clin. Anesth.*, 22(4), 233–236. doi:10.1016/j.jclinane.2010.02.003
- 7 Akbarzadeh, B., & Maenhout, B. (2023a). Real life data for OR scheduling problem. Mendeley Data V2. doi:10.17632/n2v49z2vnp.2
- 8 Akbarzadeh, B., & Maenhout, B. (2023b). RealLife OR scheduling dataset, 2021-Jan-May. Mendeley Data V1. doi:10.17632/c8d342266x.1
- 9 Perron, L., & Furnon, V. *CP-SAT: a CP Solver*. Google OR-Tools. developers.google.com/optimization/cp
- 10 Baptiste, P., Le Pape, C., & Nuijten, W. (2001). *Constraint-Based Scheduling*. Kluwer. doi:10.1007/978-1-4615-1479-4
- 11 Vilím, P. (2004). $O(n \log n)$ filtering for unary resource constraints. *CPAIOR 2004*. doi:10.1007/978-3-540-24664-0_15
- 12 Schutt, A., Feydy, T., Stuckey, P.J., & Wallace, M.G. (2009). Why cumulative decomposition is not as bad as it sounds. *CP 2009*. doi:10.1007/978-3-642-04244-7_45
- 13 Laborie, P. (2009). IBM ILOG CP Optimizer for detailed scheduling illustrated on three problems. *CPAIOR 2009*. doi:10.1007/978-3-642-01929-6_5